



Politechnika Warszawska
Wydział Elektroniki i Technik Informacyjnych

Pracownia dyplomowa inżynierska (PDI1)

Rozpoznawanie modulacji sygnałów cyfrowych z użyciem sieci neuronowych.

Autor: Klaudia Szary 331537

Data: 8 czerwca 2026

Spis treści

1	Wstęp	2
2	Przygotowanie zbioru danych	2
3	Wykorzystane modele i konfiguracja procesu uczenia	3
4	Wyniki modeli	5
5	Najlepszy model	6
5.1	Weryfikacja modelu na danych rzeczywistych	8

1 Wstęp

W bieżącym semestrze realizacja pracy dyplomowej koncentrowała się na części praktycznej. Wykonane prace obejmowały przygotowanie zbioru danych zawierającego diagramy konstelacji w dziedzinie I/Q dla wybranych modulacji cyfrowych. Zbiór został wygenerowany dla różnych warunków transmisyjnych.

Kolejnym etapem było przeprowadzenie procesu uczenia modeli wykorzystujących sieci neuronowe. W ramach badań przetestowano różne architektury sieci konwolucyjnych oraz przeprowadzono analizę ich skuteczności w zadaniu klasyfikacji modulacji cyfrowych na podstawie obrazów konstelacji.


2 Przygotowanie zbioru danych

Zbiór danych wykorzystany w pracy został przygotowany w środowisku MATLAB z wykorzystaniem wbudowanych funkcji służących do generowania sygnałów i diagramów konstelacji dla różnych modulacji cyfrowych. Opracowany zbiór obejmuje 17 rodzajów modulacji cyfrowych: APSK16, APSK32, APSK64, APSK128, ASK4, ASK8, BPSK, GMSK, PSK8, PSK16, PSK32, QPSK, QAM16, QAM32, QAM64, QAM128 oraz QAM256.


Dla każdej modulacji wygenerowano obrazy diagramów konstelacji przedstawiające rozmieszczenie symboli w płaszczyźnie I/Q. W celu odwzorowania warunków występujących w rzeczywistych systemach transmisyjnych do sygnałów wprowadzono różne rodzaje zakłóceń i niedoskonałości toru transmisyjnego:

- Stosunek sygnału do szumu (SNR – Signal to Noise Ratio), którego zmiana wpływa na rozrzut punktów konstelacji wokół ich idealnych położań.
- Niezrównoważenie amplitudowe torów I i Q (Amplitude Imbalance), powodujące różnice w amplitudzie obu składowych sygnału.
- Niezrównoważenie fazowe (Phase Imbalance), skutkujące odchyleniem kąta pomiędzy składowymi I i Q od wartości idealnej.
- Przesunięcie częstotliwości nośnej (CFO – Carrier Frequency Offset), które występuje w wyniku niedokładności synchronizacji częstotliwości pomiędzy nadajnikiem i odbiornikiem.

Łącznie wygenerowano 26,216 obrazów diagramów konstelacji. Każdy obraz przedstawia wyłącznie punkty konstelacji na jednolitym tle, bez dodatkowych opisów, osi współrzędnych czy elementów graficznych. Tak przygotowany zbiór danych został następnie podzielony na zbiory treningowy, walidacyjny oraz testowy w proporcji: 70% 15% 15% i wykorzystany w procesie uczenia oraz oceny modeli.



Rysunek 1: Przykładowe diagramy konstelacji dla modulacji APSK16, GMSK oraz QPSK



Rysunek 2: Przykładowe diagramy konstelacji dla modulacji QAM64, PSK8 oraz QAM128

3 Wykorzystane modele i konfiguracja procesu uczenia

Do analizy wykorzystano cztery architektury sieci neuronowych: ResNet18, ResNet50, EfficientNet-B0 oraz Vision Transformer (ViT-B/16). Wszystkie modele zostały zainicjalizowane wagami pochodzącymi z procesu pretrenowania na zbiorze ImageNet, a następnie dostosowane do zadania klasyfikacji siedemnastu klas modulacji cyfrowych.

ResNet18

Dla modelu ResNet18 przeprowadzono dwa warianty eksperymentów:

Wariant 1 – od początku procesu uczenia trenowane były jednocześnie:

- ostatni blok sieci Layer4,
- warstwa klasyfikacyjna FC.

Dla obu części modelu zastosowano różne wartości współczynnika uczenia.

Wariant 2 – zastosowano strategię dwuetapową:

- Stage 1 – trenowana była wyłącznie warstwa klasyfikacyjna FC,

- Stage 2 – odblokowano blok Layer4 i kontynuowano proces dostrajania modelu.

Na poszczególnych etapach stosowano indywidualnie dobrane współczynniki uczenia dla warstwy FC oraz Layer4.

Wariant 3 – zastosowano strategię trzyetapową

- Stage 1 – trenowana była wyłącznie warstwa klasyfikacyjna FC,
- Stage 2 – odblokowano blok Layer4 i kontynuowano proces dostrajania modelu,
- Stage 3 – odblokowano wszystkie warstwy sieci, umożliwiając pełne dostrajanie modelu.

Celem zastosowania trzeciego wariantu było sprawdzenie, czy dostrojenie wcześniejszych warstw ekstrakcji cech pozwoli poprawić skuteczność klasyfikacji diagramów konstelacji. Uzyskane wyniki nie wykazały jednak istotnej poprawy jakości klasyfikacji w porównaniu z wariantem dwuetapowym. Osiągnięta dokładność testowa wyniosła 88,61%, podczas gdy dla wariantu dwuetapowego uzyskano 89,55%.

Uzyskane wyniki wskazują, że najważniejsze dla adaptacji modelu do zadania klasyfikacji diagramów konstelacji było dostrojenie warstwy klasyfikacyjnej oraz ostatniego bloku Layer4. Dalsze odblokowywanie wcześniejszych warstw sieci nie przełożyło się na zauważalną poprawę wyników. Z tego względu w kolejnych testach nie stosowano odblokowywania wszystkich warstw sieci dla pozostałych architektur.

ResNet50

Dla modelu ResNet50 przeprowadzono dwa warianty eksperymentów:

Wariant 1 – jednoczesne trenowanie:

- warstwy klasyfikacyjnej FC,
- bloku Layer4.

Wariant 2 – strategia trzyetapowa:

- Stage 1 – trenowana była wyłącznie warstwa klasyfikacyjna FC,
- Stage 2 – po 5 epokach odblokowano ostatni blok rezydualny `layer4[2]`,
- Stage 3 – po 12 epokach odblokowano cały blok Layer4.

Na każdym etapie stosowano indywidualnie dobrane współczynniki uczenia dla poszczególnych części modelu.

EfficientNet-B0

W modelu EfficientNet-B0 zmodyfikowano oryginalną warstwę klasyfikacyjną. Zastosowany klasyfikator składał się z: Dropout, Linear, ReLU, Linear. Proces uczenia realizowano dwuetapowo:

- Stage 1 – trenowany był wyłącznie klasyfikator.
- Stage 2 – po 5 epokach odblokowano końcową część ekstraktora cech (`features[6:]`), a następnie kontynuowano proces dostrajania modelu przy zastosowaniu różnych współczynników uczenia dla klasyfikatora i części odpowiedzialnej za ekstrakcję cech.
- Stage 3 – po 15 epokach odblokowano cały ekstraktor cech (`features`), umożliwiając pełne dostrojenie modelu.

Dla części odpowiedzialnej za ekstrakcję cech zastosowano mniejszy współczynnik uczenia niż dla klasyfikatora.

W drugim wariantcie zastosowano rozbudowany klasyfikator o następującej strukturze: Dropout Linear, ReLU, Dropout Linear, ReLU, Linear

Proces uczenia realizowano trójetapowo:

- Stage 1 – trenowany był wyłącznie klasyfikator.
- Stage 2 – po 5 epokach odblokowano końcową część ekstraktora cech (`features[6:]`), a następnie kontynuowano proces dostrajania modelu przy zastosowaniu różnych współczynników uczenia dla klasyfikatora i części odpowiedzialnej za ekstrakcję cech.
- Stage 3 – po 15 epokach odblokowano cały ekstraktor cech (`features`), umożliwiając dostrojenie modelu.

Vision Transformer (ViT-B/16)

W modelu Vision Transformer zastosowano zmodyfikowaną głowicę klasyfikacyjną składającą się z: Dropout, Linear, GELU, Linear

Uczenie modelu przeprowadzono w trzech etapach:

- **Stage 1** – trenowana była wyłącznie głowica klasyfikacyjna,
- **Stage 2** – po 5 epokach odblokowano warstwę `encoder layer 11`,
- **Stage 3** – po 10 epokach odblokowano również warstwę `encoder layer 10`.

Na każdym etapie stosowano indywidualnie dobrane współczynniki uczenia dla poszczególnych części modelu.

4 Wyniki modeli

Tabela 1: Porównanie skuteczności testowanych modeli

Model	Epoki	Test accuracy	Val loss
ResNet18 (FC+L4)	20	0.8820	0.34
ResNet18 (Stage2)	20	0.8955	0.30
ResNet18 (Stage3)	20	0.8861	0.35
ResNet50 (FC+L4)	20	0.8873	0.35
ResNet50 (Stage3)	20	0.8542	0.53
EfficientNet-B0 (Stage3, cls1)	25	0.8580	0.40
EfficientNet-B0 (Stage3, cls2)	35	0.8621	0.43
ViT-B/16 (Stage3)	30	0.8170	1.35

Tabela 2: Porównanie metryk klasyfikacji dla testowanych modeli

Model	Precision	Recall	F1-score
ResNet18 (FC+L4)	0.8979	0.8811	0.8842
ResNet18 (Stage2)	0.9059	0.8947	0.8975
ResNet18 (Stage3)	0.8933	0.8824	0.8835
ResNet50 (FC+L4)	0.8924	0.8848	0.8864
ResNet50 (Stage3)	0.8801	0.8499	0.8539
EfficientNet-B0 (Stage3, cls1)	0.8660	0.8551	0.8570
EfficientNet-B0 (Stage3, cls2)	0.8692	0.8591	0.8613
ViT-B/16 (Stage3)	0.8301	0.8151	0.8146

5 Najlepszy model


Najlepsze wyniki spośród wszystkich analizowanych architektur uzyskano dla modelu ResNet18 trenowanego z wykorzystaniem strategii dwuetapowej. Model osiągnął dokładność klasyfikacji na poziomie **89,55%**, a także najwyższe wartości metryk Precision, Recall oraz F1-score spośród wszystkich przeprowadzonych eksperymentów.

Analiza metryk dla poszczególnych klas wskazuje, że model bardzo dobrze rozpoznawał modulacje APSK oraz QAM, dla których wartości F1-score przekraczały często 0,95. Nieco słabsze wyniki uzyskano dla klas BPSK, PSK16, PSK32 oraz QPSK. Może to wynikać z większego podobieństwa geometrycznego diagramów konstelacji tych modulacji oraz wpływu zakłóceń dodanych podczas generowania zbioru danych.


Tabela 3: Metryki klasyfikacji dla modelu ResNet18 (Stage 2) na zbiorze testowym

Klasa	Precision	Recall	F1-score	Support
APSK128	1.0000	0.9463	0.9724	205
APSK16	0.9958	0.9634	0.9793	246
APSK32	0.9337	0.9683	0.9506	189
APSK64	0.9588	0.9749	0.9668	239
ASK4	1.0000	0.9600	0.9796	225
ASK8	0.9784	1.0000	0.9891	227
BPSK	0.8000	0.7895	0.7947	228
GMSK	0.9652	0.8622	0.9108	225
PSK16	0.7043	0.8044	0.7510	225
PSK32	0.8895	0.7156	0.7931	225
PSK8	0.9355	0.7665	0.8426	227
QAM128	0.9864	0.8821	0.9313	246
QAM16	0.9646	0.9959	0.9800	246
QAM256	0.8704	0.9553	0.9109	246
QAM32	0.9598	0.9637	0.9618	248
QAM64	0.9153	0.9153	0.9153	248
QPSK	0.5431	0.7456	0.6285	228
Accuracy	-	-	0.8955	3923
Macro avg	0.9059	0.8947	0.8975	3923
Weighted avg	0.9065	0.8955	0.8982	3923

Analiza metryk dla poszczególnych klas wskazuje, że model bardzo dobrze rozpoznawał modulacje APSK oraz QAM, dla których wartości F1-score przekraczały często 0,95. Nieco słabsze wyniki uzyskano dla klas BPSK, PSK16, PSK32 oraz QPSK. Może to wynikać z większego podobieństwa geometrycznego diagramów konstelacji tych modulacji oraz wpływu zakłóceń dodanych podczas generowania zbioru danych.



Rysunek 3: Przebieg funkcji dokładności i straty dla modelu ResNet18




Rysunek 4: Macierz pomyłek dla modelu ResNet18

5.1 Weryfikacja modelu na danych rzeczywistych

Po zakończeniu procesu uczenia najlepszy model, ResNet18 (Stage2), został poddany dodatkowej weryfikacji na zbiorze rzeczywistych diagramów konstelacji, które nie były wykorzystywane podczas trenowania ani walidacji.

Zbiór testowy obejmował 36 obrazów przedstawiających różne modulacje cyfrowe, między innymi APSK16, APSK32, BPSK, GMSK, PSK8, QPSK, QAM16, QAM32, QAM64, QAM128 oraz QAM256. Obrazy pochodziły z rzeczywistych pomiarów i różniły się od danych syntetycznych wykorzystywanych podczas procesu uczenia.

Model poprawnie sklasyfikował 30 z 36 analizowanych obrazów, osiągając skuteczność równą $83,33\%$.



Rysunek 5: Przykładowe diagramy konstelacji rzeczywistych dla modulacji QAM128, QPSK oraz APSK16

Najwyższą skuteczność uzyskano dla modulacji APSK16, APSK32, PSK8, QAM16, QAM32, QAM64, QAM256 oraz QPSK, dla których większość lub wszystkie próbki zostały sklasyfikowane poprawnie. Dodatkowo model osiągał wysokie wartości pewności predykcji, często przekraczające 90%.

Największe trudności wystąpiły w przypadku modulacji GMSK oraz części próbek BPSK i QAM128. W tych przypadkach model przypisywał obrazy do klas o zbliżonych cechach geometrycznych, takich jak ASK4, ASK8 lub APSK64. Mimo występowania pojedynczych błędów klasyfikacji model zachował zdolność rozpoznawania większości analizowanych modulacji.